Reporte EDA - Los IABoys.

Introducción.
El presente proyecto busca la creación de un modelo de inteligencia artificial capaz de predecir el posible volumen que tendrán ciertas presas mexicanas seleccionadas previamente en base al análisis de sus registros históricos durante determinados lapsos de tiempo. Estos registros fueron tomados de las páginas oficiales de CONAGUA:

- CSV de registros de cada presa
- Inventario con metadatos extra de cada presa

En este análisis EDA se describirán los criterios de selección y las acciones hechas para la limpieza de los datasets originales, también se analizará una de las presas como ejemplo general por medio de las respectivas gráficas y observaciones (Cuanto se llena, cuanto se vacía, la razón de cambio del volumen del agua, datos faltantes y cobertura de estos, etc)

Criterios de selección y limpieza.
Cabe recalcar que los inicios de los registros entre presas varían bastante, algunos empiezan aproximadamente en 1930 siendo estos los más antiguos, hasta otros que empezaban en 1970, además de que durante estos periodos de tiempo los datos eran pocos o prácticamente inexistentes. Sin embargo la mayoría de presas comenzaban a tener registros más completos a partir del año 1995 por lo que se decidió hacer un corte desde la fecha del 01 de enero de 1995 hasta el 26 de octubre del 2026, esta última siendo la fecha de consulta de los datasets.

Teniendo en cuenta el corte a partir de la fecha indicada se procedió formalmente con la selección y limpieza de los dataset. Los principales criterios fueron:

- Registros mayormente completos a partir de 1995
- Al menos el 98% de días registrados con respecto al total de días pasados hasta la fecha de corte (Es decir, alrededor de 233 días faltantes serían el límite)
- El máximo de registros faltantes con respecto al volumen almacenado de agua (VolumenAlm) es de 60, es decir, el 0.52% total de registros.
- Una cobertura de la lluvia en un 95% de los registros y por lo menos un 90% en los últimos 5 años con respecto a la fecha de corte.
- Al menos un 5% de registros con lluvia mayor a 0, si solo se reportan 0’s entonces probablemente no se ha medido correctamente.

Tras un proceso de selección se dejaron las siguientes presas como opciones viables para el posterior entrenamiento del modelo:

1. CCHNL: Cuchillo Solidaridad
2. CPRNL: José López Portillo
3. EPLGJ: El palote

4. INFMC: Infiernillo
5. LBQCH: La boquilla
6. LDCJL: Lago de Chapala
7. PMHSI: Miguel Hidalgo
8. SLSGJ: Solis
9. VBRMX: Valle de Bravo

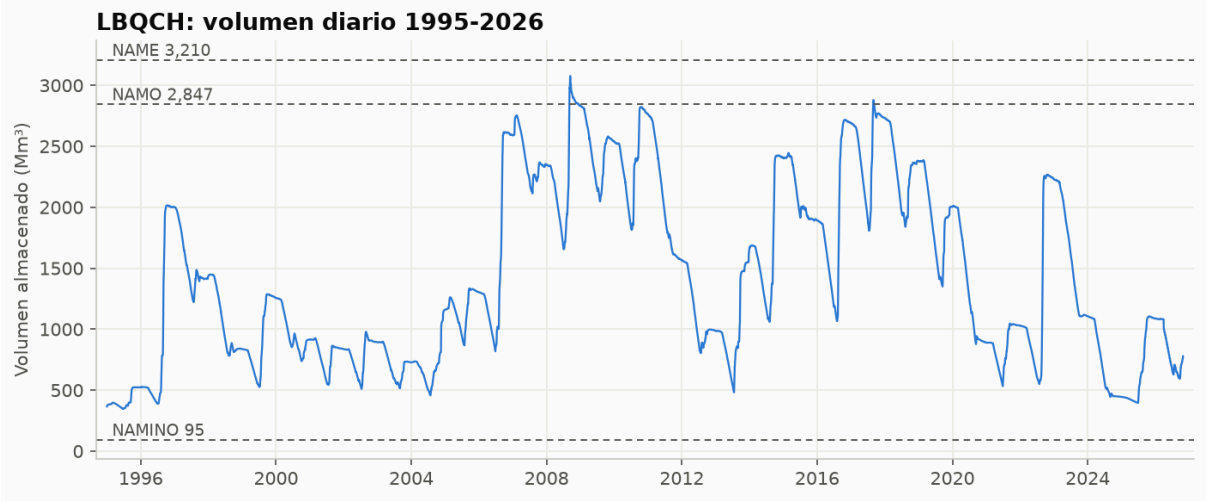
Se consideró que las presas anteriormente mencionadas cumplen con los criterios establecidos, entre ellas siendo *La Boquilla* tomada como presa referencial al contar con mejores reportes de datos.

Datos referenciales de la presa.
A manera de dar contexto, estos son los datos correspondientes a los 3 niveles oficiales de *La Boquilla*:

Nivel	Volumen (Mm^3)	Significado
NAME	3209.63	Nivel máximo de operación extraordinario
NAMO	2846.78	Nivel máximo de operación normal
NAMINO	94.84	Nivel mínimo de operación

En casi todo el reporte el valor que más se usa como referencia es el NAMO.

Serie completa (Volumen a lo largo del tiempo)



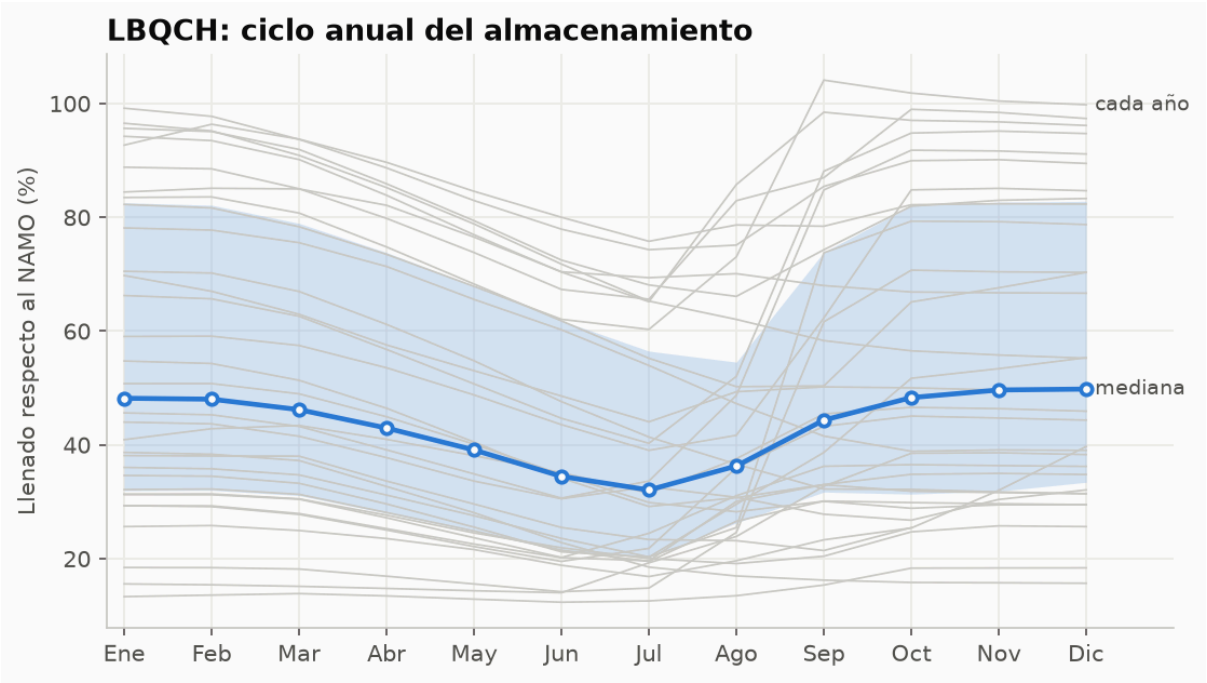
Recordando: Los registros fueron recortados desde 1995 hasta el 26 de agosto de 2026, es decir, 11622 días/registros en total.
En esta serie podemos ver principalmente 3 periodos:

- **1995 - 2005:** Fue una época de niveles bajos de agua, en 1997 aproximadamente fue el nivel más alto de ese periodo.
- **2006 - 2020:** Esta es la época de mayores niveles alcanzados, tuvo un pico bajo aproximadamente en 2013.

- **2021 - Actualidad:** A partir de acá el volumen comenzó a bajar de nuevo, en 2023 ocurrió el pico más alto de este periodo.

El pico más alto alcanzado ocurrió el 12 de septiembre del 2008 con un volumen de 3076.61 Mm³ superando el NAMO, mientras que el pico más bajo ocurrió el 30 de junio de 1995 con un volumen de 347.33 Mm³ relativamente cercano al NAMINO.

Porcentaje de llenado por mes con respecto al NAMO.

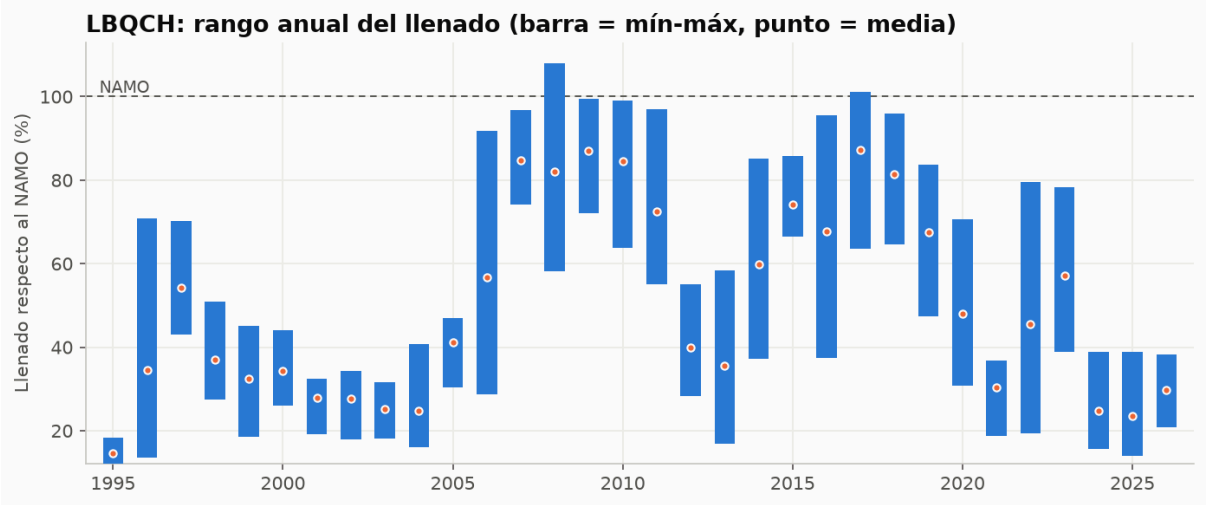


La mediana es la linea más gruesa de color azul, las líneas delgadas grises son cada año (que cabe resaltar que cada línea empieza en niveles diferentes de llenado) y la banda de azul claro es la mitad central de los años.

Aquí podemos notar que el valor más bajo con respecto a la mediana corresponde aproximadamente a un 35% del NAMO en el mes de julio, a partir de agosto es cuando comienza a recuperarse de nuevo hasta llegar a diciembre en donde alcanza su periodo más alto aproximadamente del 49.8%

Esto cuadra con las estaciones del año pues el nivel más bajo se encuentra en el periodo de verano mientras que su recuperación parte desde finales de esta estación aproximadamente y se mantiene en niveles estables durante noviembre hasta febrero. Es por esto que el mes del año también será relevante para el dataset.

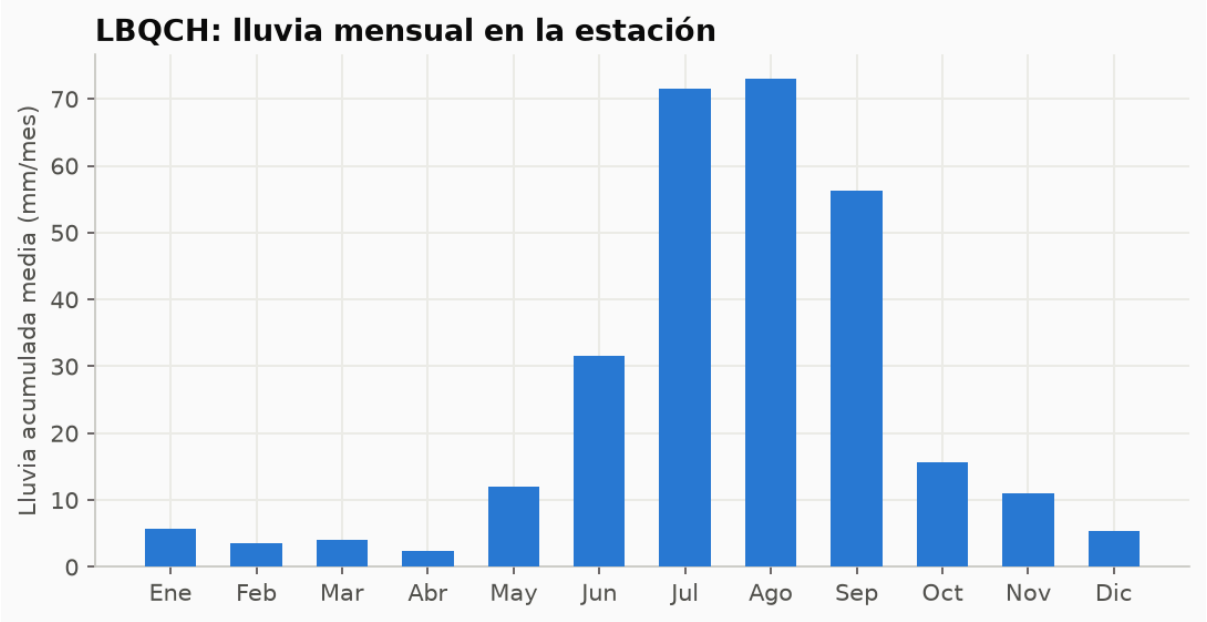
Comparativa de llenado por año.



Aquí podemos ver de forma más clara el porcentaje de llenado de la presa con respecto al NAMO por año desde su mínimo hasta su máximo. Si tomamos los años más “significativos” se leerían así:

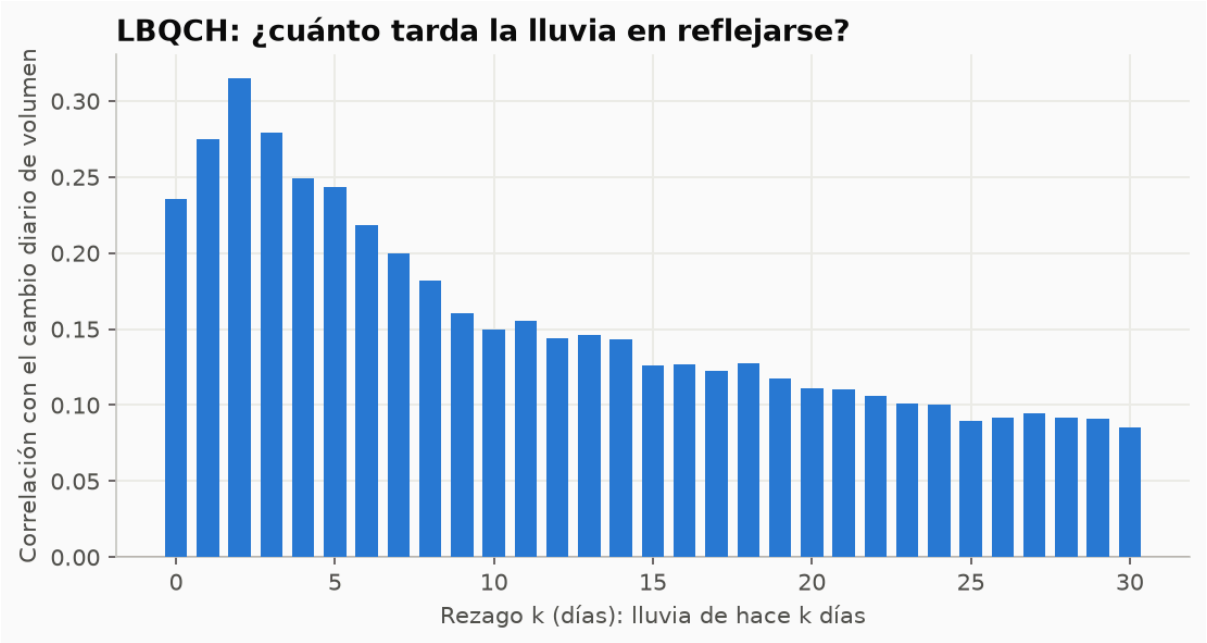
Año	Mínimo %	Máximo %	Razón
1995	12,2	18.4	Año con mayor escasez
2006	28.8	91.9	Año con un buen crecimiento
2008	58.2	108.1	Año pico con el mayor volumen
2013	16.9	58.4	Decaída del volumen
2017	63.5	101.2	Segundo año pico en volumen
2020	30.8	70.7	Decaída del volumen

Lluvia por mes.



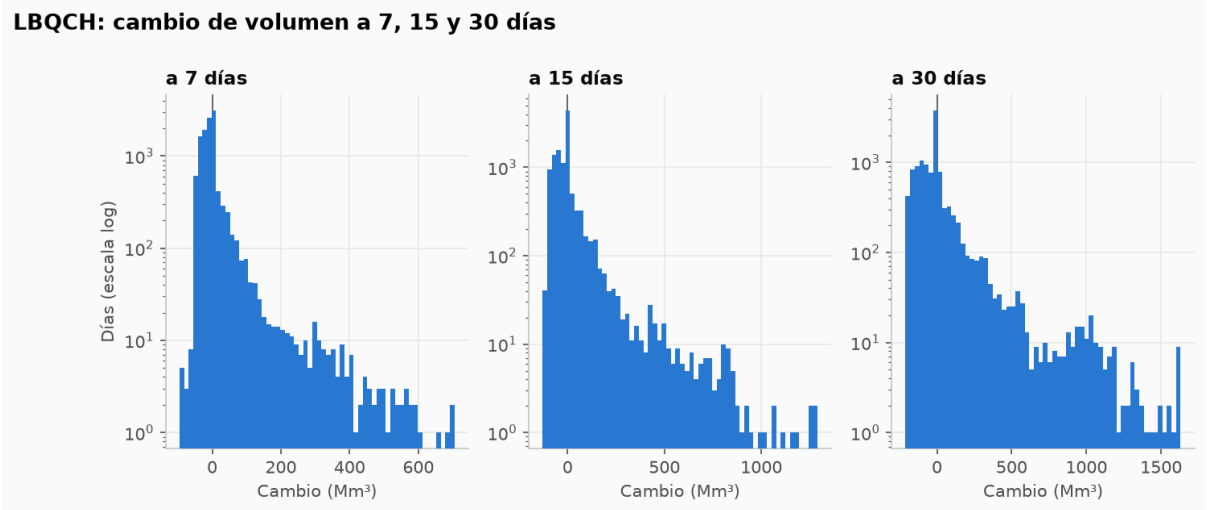
Aquí podemos ver que el periodo con mayores lluvias abarca desde julio hasta septiembre, siendo el 28 de junio de 2021 el día con mayor lluvia con un valor de 140 mm. Aunque prácticamente el 84% de los días en total no llueve dando valores de 0 o muy bajos casi siempre y repentinamente trae valores grandes.

Tiempo en que tarda la lluvia en reflejarse



Aquí podemos observar la correlación entre la lluvia de hace K días con el volumen del día actual. De acuerdo con la gráfica más o menos la relación aparece con 2 días de retraso, aproximadamente un 0.31 de correlación y baja de a poco pero sin llegar hasta 0 realmente cuando pasan 30 días. Esto nos indica que el efecto de la lluvia si bien no es inmediato, si puede ser duradero por semanas.

Cambio de volumen en 7, 15 y 30 días.



En estas gráficas se muestran los cambios de volumen para cada periodo de días esperados y, por tanto, que el modelo debe predecir. Estos son los valores relevantes para cada uno:

Plazo	Baja fuerte (Percentil 1)	Cambio típico (Mediana)	Sube fuerte (Percentil 99)
7 días	-48.3 (-1.7%)	-3.3 (-0.12%)	+272.9 (+9.6%)
15 días	-101.2 (-3.6%)	-7.1 (-0.25%)	+507.3 (+17.8%)
30 días	-194.8 (-6.8%)	-14.0 (-0.49%)	+960.9 (+33.8%)

Que casi siempre hayan valores negativos indica que la presa se va vaciando poco a poco, es decir, las bajadas de volumen son lentas y las subidas pueden ser enormes pero poco frecuentes.

Conclusiones (Resumen):

- Esta serie está considerablemente completa sin huecos relevantes
- La estacionalidad es clara e influye por lo que conviene incluir el mes
- La lluvia influye con un retraso de 1 a varios días
- Las subidas de volumen de agua son fuertes pero poco frecuentes y las bajadas son frecuentes pero lentas
- La referencia de persistencia (0.76%, 1.58% y 3.02% del NAMO a 7, 15 y 30 días) es el error que el modelo debe mejorar